

Weekly Report - 2026-07-05

本周与上周的不同点

项目	上周	本周
Skill library 使用	主要使用 frozen SWEGym skill library	增加 test-time session skills : writer 从 benchmark public trace 提 evidence , evaluator 在无 verifier 输入下裁决 candidate
Verifier 边界	容易混淆“verifier 用于进化”和“verifier 用于报告”	明确 : test-time evolution 不向 writer/evaluator 输入 verifier ; verifier 只在 gate 完成后报告 recovered , 并构造下一轮 unresolved subset

最新实验结果

当前完成的 GLM-5.2 / Pi / SWE-Bench Verified 结果如下 :

Setting	Trial s	Resolved	Rate	说明
No Skills baseline	500	368	73.6 %	不使用 skill library
Frozen SWEGym library	500	376	75.2 %	直接使用 frozen downstream skills
TTS Gate 1 full eval	500	379	75.8 %	初始 online gate , 全量评测
TTS Gate 2 subset-composed	500	410	82.0 %	第一轮 TTS EVO
TTS Gate 3 subset-composed	500	423	84.6 %	第二轮 TTS EVO

SWEGym Val Gate Resolve Rate



SWEGym validation gate resolve rate

当前运行状态：

- 八轮控制器已启动，目标为 gates 2..8。
- Gate 2 已完成：额外 31 unresolved = 90。
- Gate 3 已完成：额外 13 unresolved = 77。
- Gate 4 已从 77 个 unresolved tasks 开始运行。
- 之前的 Gate 2 full-500 rerun 不作为主结果，因为它不符合 subset-composition 协议。

本周产出

- 明确并实现了 downstream test-time skill evolution 的 subset-composition 计分方式。
- 启动了 SWE-Bench Verified 上的八轮 TTS evolution。
- 将论文中的 downstream protocol、current pilot result、limitation 和 implementation notes 同步到 `paper/main.tex`。
- 新增本周周报，记录协议变化、修改原因和最新实验结果。

下周建议

1. 等待 Gate 4..8 完成，补齐 cumulative recovery 曲线。
2. 对 recovered cases 做定性分析：哪些 failure-mode/session skills 真正起作用。
3. 只做 main results 时，优先稳定 GLM-5.2 / Pi 的完整曲线，再扩展到其他 model/harness cell。